

Caso Práctico - Análisis de datos de la copa mundial de fútbol con Apache Spark

Navarro, E. (2026). *Caso Práctico Análisis de datos de la copa mundial de fútbol con Apache Spark*. [Guía]. Universidad Andrés Bello, Santiago, Chile.


Contexto del caso

La Copa Mundial de la FIFA es el torneo de fútbol más prestigioso del mundo, celebrado cada cuatro años desde 1930. Millones de aficionados siguen cada partido, y los datos generados proporcionan información valiosa sobre el rendimiento de equipos, jugadores y estadios.

Como Analista de Datos Deportivos, tu tarea es utilizar Apache Spark y DataFrames para realizar un análisis exhaustivo de los datos de la Copa Mundial, aplicando todas las técnicas aprendidas en los recursos anteriores: RDDs, DataFrames, Spark SQL, transformaciones, acciones, agregaciones y optimización.

Esta actividad formativa te preparará para la evaluación sumativa de la Semana 2.

Modelo de datos



Descripción de los datasets

Se proporcionan 5 archivos de datos:

1. jugadores.csv (80 registros)

Columna	Tipo	Descripción
jugador_id	Integer	Identificador único del jugador
nombre	String	Nombre del jugador
apellido	String	Apellido del jugador
edad	Integer	Edad del jugador en años
altura	Integer	Altura del jugador en centímetros
peso	Integer	Peso del jugador en kilogramos
posicion	String	Posición en el campo (Portero, Defensa, Mediocampista, Delantero)
equipo_id	Integer	ID del equipo al que pertenece

2. equipos.csv (15 registros)

Columna	Tipo	Descripción
equipo_id	Integer	Identificador único del equipo
nombre	String	Nombre del país/equipo
confederacion	String	Confederación a la que pertenece (UEFA, CONMEBOL, CONCACAF, etc.)

Columna	Tipo	Descripción
ranking_fifa	Integer	Posición en el ranking FIFA

3. partidos.csv (100 registros)

Columna	Tipo	Descripción
partido_id	Integer	Identificador único del partido
equipo_local_id	Integer	ID del equipo local
equipo_visitante_id	Integer	ID del equipo visitante
goles_local	Integer	Goles anotados por el equipo local
goles_visitante	Integer	Goles anotados por el equipo visitante
estadio_id	Integer	ID del estadio donde se jugó
torneo_id	Integer	ID del torneo
fase	String	Fase del torneo (Fase de Grupos, Octavos, Cuartos, Semifinal, Final)

4. estadios.csv (10 registros)

Columna	Tipo	Descripción
estadio_id	Integer	Identificador único del estadio
nombre	String	Nombre del estadio

Columna	Tipo	Descripción
ciudad	String	Ciudad donde se ubica
pais	String	País donde se ubica
capacidad	Integer	Capacidad de espectadores

5. torneos.json (3 registros)

Campo	Tipo	Descripción
torneo_id	Integer	Identificador único del torneo
nombre	String	Nombre del torneo
anio	Integer	Año de celebración
pais_sede	String	País sede del torneo
campeon	String	Equipo campeón
subcampeon	String	Equipo subcampeón

Tareas a realizar

El trabajo debe desarrollarse en un Notebook ejecutable (Google Colab) y debe incluir la siguiente estructura:

Parte 1: Configuración inicial del entorno

- 1.1. Instalar Apache Spark y Java en el entorno de ejecución.
- 1.2. Crear las variables de entorno necesarias.

1.3. Crear la SparkSession con el nombre "MundialAnalysis" y el SparkContext.

Parte 2: RDDs - Creación y unión (ID 3.1)

2.1. Crear un RDD llamado jugador1 con 6 particiones, leyendo el archivo jugadores.csv.

2.2. Crear un segundo RDD llamado jugador2 con 6 particiones, leyendo nuevamente el archivo jugadores.csv (simula tener dos fuentes de datos).

2.3. Crear un nuevo RDD llamado jugadorTotal que contenga la unión de los RDDs jugador1 y jugador2.

2.4. Mostrar la cantidad de registros contenidos en jugadorTotal.

2.5. Convertir el RDD jugadorTotal en un DataFrame llamado jugadores con las siguientes columnas: "jugador_id", "nombre", "apellido", "edad", "altura", "peso", "posicion", "equipo_id".

2.6. Mostrar el esquema y los tipos de datos utilizables del DataFrame jugadores.

Parte 3: RDDs - Transformaciones (ID 3.2)

3.1. Crear un RDD llamado MayorEdad que permita filtrar jugadores mayores de 30 años.

3.2. Crear un RDD llamado Jugadores_Defensa que muestre solo los jugadores cuya posición sea "Defensa".

3.3. Convertir a mayúsculas todas las palabras (nombre y apellido) del RDD jugadorTotal.

Parte 4: DataFrames - Creación e integración (ID 3.1)

4.1. Crear los DataFrames Equipos, Partidos, Estadios y Torneos a partir de los archivos equipos.csv, partidos.csv, estadios.csv y torneos.json.

4.2. Realizar la optimización de los DataFrames creados (aplicar .cache() o .persist() según corresponda).

4.3. Crear un nuevo DataFrame llamado mundial_completo que contenga los datos de todos los DataFrames (jugadores, equipos, partidos, estadios y torneos) mediante operaciones de join.

Parte 5: Paralelismo (ID 3.4)

5.1. Paralelizar el DataFrame mundial_completo a 5 particiones.

5.2. Verificar el número de particiones del DataFrame resultante.

Parte 6: Inspección del dataframe (ID 3.1)

6.1. Mostrar la cantidad de filas, el tipo de datos y el esquema del DataFrame mundial_completo.

Parte 7: Columnas calculadas (ID 3.3)

7.1. Crear una columna calculada llamada IMC que determine el Índice de Masa Corporal de cada jugador usando la fórmula:

$$\text{IMC} = \text{peso} / (\text{altura}/100)^2$$

7.2. Crear una columna calculada llamada Categoria_Edad que determine la categoría del jugador:

- "Joven" si edad < 25
- "Experimentado" si edad entre 25 y 32
- "Veterano" si edad > 32

7.3. Crear una columna calculada llamada Resultado_Partido que determine el resultado del partido:

- "Victoria Local" si goles_local > goles_visitante
- "Victoria Visitante" si goles_visitante > goles_local
- "Empate" si goles_local == goles_visitante

Parte 8: Agregaciones con Spark SQL (ID 3.3)

Registre el DataFrame mundial_completo como una vista temporal llamada "Mundial" y utilice Spark SQL para responder:

8.1. ¿Cuántos jugadores hay por equipo? (Conteo de jugadores agrupado por nombre de equipo)

8.2. ¿Cuál es la edad promedio, mínima y máxima de los jugadores, agrupado por posición?

8.3. ¿Cuál es la altura promedio, mínima y máxima de los jugadores, agrupado por confederación?

8.4. ¿Cuántos partidos se jugaron en cada fase del torneo?

8.5. ¿Cuál es el total de goles anotados por cada equipo (como local y visitante)?

8.6. ¿Cuál es el promedio de goles por partido en cada torneo?

8.7. ¿Cuál es la capacidad promedio de los estadios agrupados por país?

8.8. Utilizando CASE WHEN, cree una consulta SQL que agregue una columna Clasificacion_IMC con las siguientes categorías:

- "Bajo peso" si $IMC < 20$
- "Normal" si IMC entre 20 y 25
- "Sobrepeso" si $IMC > 25$

8.9. ¿Cuál es el número de victorias, derrotas y empates de cada equipo?

8.10. Utilizando HAVING, encuentre los equipos que tienen un promedio de edad mayor a 28 años.

Parte 9: Transformaciones avanzadas (ID 3.2)

9.1. Filtrar el DataFrame para mostrar solo los partidos de la fase "Final".

9.2. Seleccionar solo las columnas: nombre_jugador, apellido, posicion, nombre_equipo.

9.3. Ordenar el DataFrame por edad de mayor a menor.

9.4. Mostrar los 10 jugadores más altos del torneo.

Instrucciones de entrega

- 1 Desarrolle su análisis en un Notebook de Google Colab utilizando PySpark.
- 2 Use Spark SQL para TODAS las consultas de la Parte 8.
- 3 Documente su código con comentarios explicando cada operación.
- 4 Muestre los resultados de cada consulta usando .show().
- 5 Exporte su notebook como archivo .ipynb.

Objetivos de aprendizaje cubiertos

Esta actividad formativa cubre todos los indicadores de desempeño de la Semana 2:

- ID 3.1: Implementan estructuras de datos distribuidas mediante RDDs y DataFrames.
- ID 3.2: Ejecutan operaciones de transformación y acción sobre RDDs y DataFrames.
- ID 3.3: Implementan consultas con Spark SQL en la manipulación y exploración de datos estructurados.
- ID 3.4: Aplican técnicas avanzadas de particionamiento, persistencia y caché.

Consejos para el éxito

1. Lea cuidadosamente cada pregunta antes de comenzar a codificar.
2. Pruebe su código paso a paso, no espere al final para ejecutar todo.
3. Consulte los apuntes de la Semana 2 si tienes dudas sobre la sintaxis.
4. Use `.printSchema()` y `.show()` frecuentemente para entender la estructura de tus DataFrames.
5. Comente su código: Explique qué hace cada línea para demostrar su comprensión.

Criterios de autoevaluación

Antes de entregar, verifica que hayas completado:

- Configuración correcta del entorno Spark.
- Creación de RDDs con particiones específicas.
- Unión de RDDs.
- Transformaciones sobre RDDs (filtros, conversiones).
- ✓ Conversión RDD → DataFrame.
- Creación de DataFrames desde CSV y JSON.

- Joins entre múltiples DataFrames.
- Optimización con cache/persist.
- Particionamiento del DataFrame resultante.
- Columnas calculadas con lógica condicional.
- Al menos 10 consultas SQL con agregaciones.
- Uso de CASE WHEN y HAVING.
- Código comentado y documentado.

¡Éxito en tu actividad formativa! Este ejercicio te preparará completamente para la evaluación sumativa.